



**Instituto Politécnico Nacional**



## **Unidad Profesional Interdisciplinaria en Ingeniería y Tecnologías Avanzadas**

### **Reconocimiento de Patrones**

---

#### **Práctica 5: Clasificación de ECG mediante parámetros Sintéticos**

---

##### **Realizado por:**

Alvarez Perez	Karen Yunuen	2020640050
Becerra Chavez	Alan	2020640009
Castilla Zamora	Jonathan Eduardo	2021640173
López Navarrete	Gabriel	2020640212
Ortiz Cuapio	Manuel Alejandro	2021640462
Robellada Rodríguez	Alondra Berenice	2020640504
Romero Almazán	Rodrigo	2020640420
Villeda Ensuaestegui	Kevin Axel	2021640569

**22 de octubre de 2025**

## 1. Introducción

La clasificación de señales mediante parámetros sintéticos se refieren a medidas derivadas o calculadas a partir de características extraídas de las señales de ECG. En la presente practica se usaran dichos parámetros para determinar patrones en señales obtenidas, así como la eficiencia de los metodos utilizados para hacer la determinacion.

## 2. Marco Teórico / Principios de operación


El electrocardiograma es una herramienta fundamental en el campo de la medicina para evaluar la actividad eléctrica del corazón. La señal de ECG representa la variación en el tiempo de los potenciales eléctricos generados por las células cardíacas durante cada ciclo cardíaco. Estas señales, registradas mediante electrodos colocados en la superficie del cuerpo, proporcionan información valiosa sobre la salud del corazón y pueden ayudar en el diagnóstico de diversas afecciones cardíacas.

La clasificación de las señales de electrocardiograma implica el análisis y la categorización de patrones específicos presentes en la forma de onda. Este proceso es esencial para identificar anomalías y enfermedades cardíacas. Algunas de las categorías comunes de clasificación incluyen:

- Ondas y complejos: La identificación de las ondas P, QRS y T, así como la medición de sus intervalos, es crucial para evaluar la normalidad del ritmo cardíaco.
- Ritmo cardíaco: Clasificación de la frecuencia cardíaca como normal, bradicardia (ritmo cardíaco lento) o taquicardia (ritmo cardíaco rápido).
- Anomalías cardíacas: Detección de signos de enfermedades cardíacas, como bloqueos cardíacos, infartos de miocardio y arritmias.
- Segmento ST y onda T: Evaluar la presencia de elevaciones o depresiones del segmento ST y alteraciones en la onda T, que pueden indicar isquemia o lesiones cardíacas.

La clasificación automática de señales de ECG ha ganado relevancia con el avance de técnicas de inteligencia artificial y aprendizaje automático. Algoritmos especializados pueden analizar grandes conjuntos de datos de ECG para identificar patrones sutiles y asistir a los profesionales de la salud en la detección temprana y el tratamiento de enfermedades cardíacas.

En resumen, la clasificación de señales de ECG es esencial para interpretar la información proporcionada por estas ondas eléctricas y para realizar diagnósticos precisos en el ámbito cardiológico, contribuyendo así a la atención médica efectiva y oportuna. [1]



**Figura 1:** Características principales de ECG.

## 2.1. Parámetros sintéticos de clasificación.

En el análisis del ECG, se pueden extraer una variedad de características, como la duración de intervalos (como el intervalo RR entre latidos), la amplitud de ondas (como la amplitud de la onda P o la amplitud de la onda QRS), las pendientes, entre otros. Estas características pueden combinarse o analizarse de diversas maneras para generar parámetros sintéticos.

Los parámetros sintéticos pueden incluir medidas estadísticas, como la media, la desviación estándar, la variabilidad, así como también características más complejas, como los coeficientes de transformadas (por ejemplo, la transformada de Fourier o la transformada wavelet) aplicadas a segmentos de la señal ECG.

La clasificación de señales de ECG puede implicar el uso de algoritmos de aprendizaje automático, como las redes neuronales, máquinas de vectores de soporte (SVM), clasificadores basados en árboles, entre otros, que pueden utilizar estos parámetros sintéticos como entradas para distinguir entre diferentes condiciones cardíacas, como arritmias, infartos, etc.

## 2.2. Modelo sintético de ECG con ecuaciones ordinarias

El modelo sintético de ECG que has presentado utiliza ecuaciones ordinarias para simular las ondas características de un ciclo cardíaco.

Las expresiones matemáticas para el primer modelo sintético de ECG son las siguientes:

$$P = -\frac{AP}{2} \cos\left(\frac{2\pi k + 15}{kP}\right) + \frac{AP}{2} \quad (1)$$

$$Q = AQ \cdot (k - 0.1 \cdot kQ) \cdot \left(\frac{19.78\pi}{kQ}\right) \cdot \exp\left(-2 \cdot \left(\frac{6\pi}{kQ} \cdot (k - 0.1 \cdot kQ)\right)^2\right) \quad (2)$$

$$R = AR \cdot \sin\left(\frac{\pi k}{kR}\right) \quad (3)$$

$$S = -AS \cdot 0.1 \cdot k \cdot \frac{19.78\pi}{kS} \cdot \exp\left(-2 \cdot \left(\frac{6\pi}{kS \cdot 0.1 \cdot k}\right)^2\right) \quad (4)$$

$$T = -AT \cdot \cos\left(\frac{1.48\pi k + 15}{kT}\right) + AT + ST(\text{end}) \cdot k_{ST} \quad (5)$$

$$I = \frac{T(\text{end}) \cdot kT \cdot SI}{k + 10} \quad (6)$$

### 2.3. Estimación para Fourier de señal ECG

La Estimación para Fourier de una señal ECG (Electrocardiograma) implica descomponer la señal en sus componentes fundamentales, que son ondas sinusoidales. Esto se hace mediante la serie de Fourier, que representa la señal como una suma infinita de senos y cosenos. La serie de Fourier ayuda a analizar y entender la composición espectral de la señal.

La expresión general de la serie de Fourier para una señal  $s(t)$  es la siguiente:

$$s(t) = \frac{a_0}{2} + \sum_{i=1}^n a_i \cos(\omega t) + \sum_{i=1}^n b_i \sin(\omega t)$$

Donde  $a_0$ ,  $a_k$ , y  $b_k$  son los coeficientes de la serie de Fourier, y  $\omega$  es la frecuencia angular.

Las ecuaciones para  $a_0$ ,  $a_k$ , y  $b_k$  están relacionadas con los cálculos específicos de los coeficientes para las ondas  $P$  y  $T$  en el ECG. Estos cálculos implican la integración de la señal  $f(t)$  sobre un intervalo  $[C, C + 2\pi]$ .

Para las ondas  $P$  y  $T$ , los coeficientes  $a_0$ ,  $a_k$ , y  $b_k$  se calculan de la siguiente manera:

1.  $a_0$  se calcula como:

$$a_0 = \frac{1}{\pi} \int_C^{C+2\pi} -t^2 dt = \frac{2}{3} - T^2$$

2.  $a_k$  se calcula como:

$$a_k = \frac{1}{\pi} \int_C^{C+2\pi} -t^2 \cos(kt) dt$$

3.  $b_k$  se calcula como:

$$b_k = \int_C^{C+2\pi} t \sin(kt) dt$$

Estos cálculos se basan en la serie de Fourier y se utilizan para determinar los coeficientes que describen las componentes de frecuencia de las ondas  $P$  y  $T$  en la señal ECG.

## 2.4. Modelo dinámico de ECG (*electrocardiograma*) sintético

Por otra parte, para la respectiva simulación o generación de una señal electrocardiográfica por parámetros sintéticos, se procede a abordar el **modelo dinámico** que consta de un sistema de tres *ecuaciones diferenciales ordinarias* (ODE) de primer orden.

En este sentido, para la subsecuente implementación de la señal electrocardiográfica al involucrar un sistema de ecuaciones diferenciales dependen de una variación en el tiempo, es decir, para cada parámetro ya que este modelo busca simular de manera realista las variaciones temporales en el *electrocardiograma* (ECG), que representan la actividad eléctrica del corazón a lo largo del tiempo.

### 2.4.1. Sistema de ecuaciones diferenciales ordinarias (ODE) de 1° orden.

Para el modelo dinámico de parámetros sintéticos del *electrocardiograma* se presenta el siguiente sistema de ecuaciones:

$$\dot{x} = \alpha x - \omega y \quad (7)$$

$$\dot{y} = \alpha y + \omega x \quad (8)$$

$$\dot{z} = - \sum_{i \in [P, Q, R, S, T]} a_i \Delta \theta_i \exp \left( -\frac{\Delta \theta_i^2}{2b_i^2} \right) - (z - z_0) \quad (9)$$

Dónde es posible encontrar las consiguientes funciones auxiliares:

$$\alpha = 1 - \sqrt{x^2 + y^2} \quad (10)$$

$$\omega = 2\pi f_c \quad (11)$$

$$\Delta \theta_i = \text{mod}(\theta - \theta_i, 2\pi) \quad (12)$$

$$\theta = \text{atan2}(y, x) \quad (13)$$

$$z_0 = A \cdot \sin(2\pi f_r t) \quad (14)$$

Definidas a partir de los parámetros:

- $f_r$ : Frecuencia respiratoria en  $[Hz]$ .
- $f_c$ : Frecuencia cardiaca.

## 2.5. Consideración respecto al *diagrama de plano-fase*.

El funcionamiento de este modelo se basa en el diagrama de plano-fase en la que se contempla que las condiciones iniciales cuando se encuentre estables (se comportarán de modo atractivas) y cuando sea el caso contrario, es decir inestables (se comportarán de manera repulsiva).

$$\begin{aligned} f_1 &= x_1; \quad f_2 = y_1 \quad \text{y} \quad f_3 = z_1 \\ \dot{x} &= (\dot{f}_1) = \alpha f_1 - \omega f_2 \\ \dot{y} &= (\dot{f}_2) = \alpha f_1 + \omega f_1 \\ \dot{z} &= (\dot{f}_3) = - \sum_{i \in [P, Q, R, S, T]} a_i \Delta \theta_i \exp \left[ -\frac{\Delta \theta_i^2}{2b_i^2} \right] - z - z_0 \end{aligned}$$

Resultando que  $z$  está definida de la siguiente manera:

$$\dot{z} = \sum_{i \in [P, Q, R, S, T]} a_i \Delta \theta_i \exp \left( -\frac{\Delta \theta_i^2}{2b_i^2} \right) - z - z_0 \quad (15)$$

La siguiente tabla muestra un ejemplo de valores de parámetros iniciales.

	$P$	$Q$	$R$	$S$	$T$
$\theta_i$	$-\frac{1}{3}\pi$	$-\frac{1}{12}\pi$	0	$\frac{1}{12}\pi$	$\frac{1}{2}\pi$
$a_i$	1.2	-5	30	-7.5	0.75
$b_i$	0.25	0.1	0.1	0.1	0.4

### 3. Condiciones de experimentación

Debido a que la bradicardia es mucho más difícil de inducir que la taquicardia, las adquisiciones fueron realizadas a sujetos de prueba en reposo y justamente después de realizar 50 minutos de ejercicio aeróbico. Tanto las lecturas de reposo como de post-ejercicio tuvieron una duración de 10 minutos.

Datos	Cantidad
Sujetos de prueba	128
Registros ECG en reposo	128
Registros ECG post-ejercicio	128
Total de registros ECG	256

**Tabla 1:** Lista de registros ECG.

La adquisición de los datos fue realizada mediante el uso del siguiente equipo:

Materiales	Cantidad
Tarjeta STM32	3
Placa ECG desarrollada por el grupo	3
Pilas 9 V por placa	2
Electrodos por sujeto de prueba	3

**Tabla 2:** Materiales utilizados para la adquisición de las señales ECG.

### 4. Desarrollo de la practica

Previo a la realización de las redes neuronales fue necesario corroborar cada método sintético. Dicho cometido se logró realizando pruebas con una señal obtenida de physionet, la cual fue filtrada y normalizada.

#### 4.1. Modelo dinámico

---

**Algorithm 1** Algoritmo genético aplicado para la optimización de los parámetros del modelo dinámico
 

---

```

1: Entrada: Señal ECG, parámetros iniciales
2: Salida: Mejores parámetros encontrados, gráficos de resultados
3: Cargar datos de la función objetivo
4: Filtrar la señal ECG objetivo utilizando un filtro Butterworth
5: Aplicar una función de media móvil
6: Inicializar estructuras de los parámetros:  $a, b, \theta, f_r, f_c, A$ 
7: Definir campos a las estructuras de los parámetros  $a, b, \theta, f_r$ : P, Q, R, S, T, U(ajuste)
8: Definir valores para el algoritmo de optimización evolutivo: numIndividuos, numGeneraciones, tasaMutacion
9: Definir rangos de mutación para los parámetros
10: Definir valores iniciales de búsqueda para la población inicial
11: Generar los individuos que contienen los parámetros
12: Almacenar los individuos en una población (celda)
13: Inicializar de la población inicial aleatoria
14: Definir condiciones iniciales y parámetros del sistema
15: Generar señal objetivo
    for cada generación do
      — cada individuo en la población
16: Evaluar la función objetivo para el individuo
17:
    for cada número de parámetros de los individuos do
18:
    Seleccionar los mejores individuos
19:
20: Cruzar los mejores individuos para generar descendencia
21: Mutar algunos individuos de la descendencia
22: Combinar mejores individuos y descendencia
23: Crear la nueva población
24:
25: Encontrar el individuo con el mejor ajuste
26: Extraer los parámetros del mejor individuo
27: Asignar los atributos (campos) al mejor individuo (estructura)
28: Resolver el sistema de ecuaciones diferenciales con los mejores parámetros
29: Obtener la señal objetivo con los mejores parámetros
30: Mostrar los resultados y gráficos
  
```

---

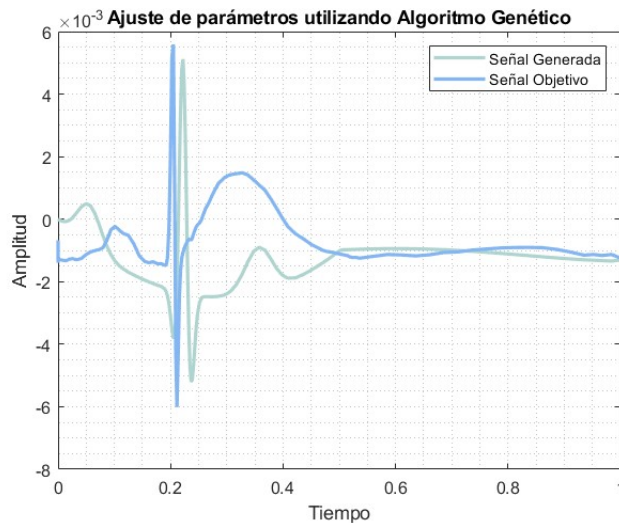


**Algorithm 2** Modelo de Red Neuronal aplicado a la separación de los datos


- 1: **Entrada:** Datos de entrenamiento  $(X, y)$  y validación  $(X_{val}, y_{val})$
- 2: **Salida:** Modelo entrenado *modelo*
- 3: Cargar bibliotecas necesarias
- 4: Leer datos de entrenamiento y validación
- 5: Preprocesar datos
- 6: Crear modelo secuencial
- 7: Capa oculta con 40 nodos y función de activación sigmoide
- 8: Capa oculta con 80 nodos y función de activación sigmoide
- 9: Capa oculta con 40 nodos y función de activación sigmoide
- 10: Capa de salida con 2 nodos y función de activación softmax
- 11: Compilar el modelo
- 12: Entrenar el modelo en  $X, y$  durante 100 épocas, con datos de validación  $X_{val}, y_{val}$
- 13: Visualizar resultados (precisión y pérdida) usando matplotlib.pyplot
- 14: **Salida:** *modelo* entrenado

#### 4.1.1. Resultados: Obtención de la *señal deseada* de un sujeto de prueba a partir de la resolución de las ecuaciones del modelo dinámico.

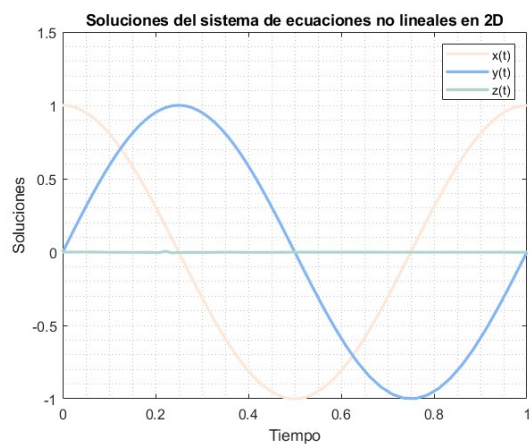
En este sentido, es posible visualizar la obtención de la *señal ECG generada* por el *Algoritmo Genético* obteniéndose los parámetros:  $a_{P,Q,R,S,T}$ ,  $b_{P,Q,R,S,T}$ ,  $\theta_{P,Q,R,S,T}$ ,  $f_c$ ,  $f_r$  y  $A$  que resuelven el sistema de *ecuaciones diferenciales* del *modelo dinámico* que se aproximan a simular la señal electrocardiográfica buscada (*señal objetivo*).



**Figura 2:** ECG generado por modelo dinámico

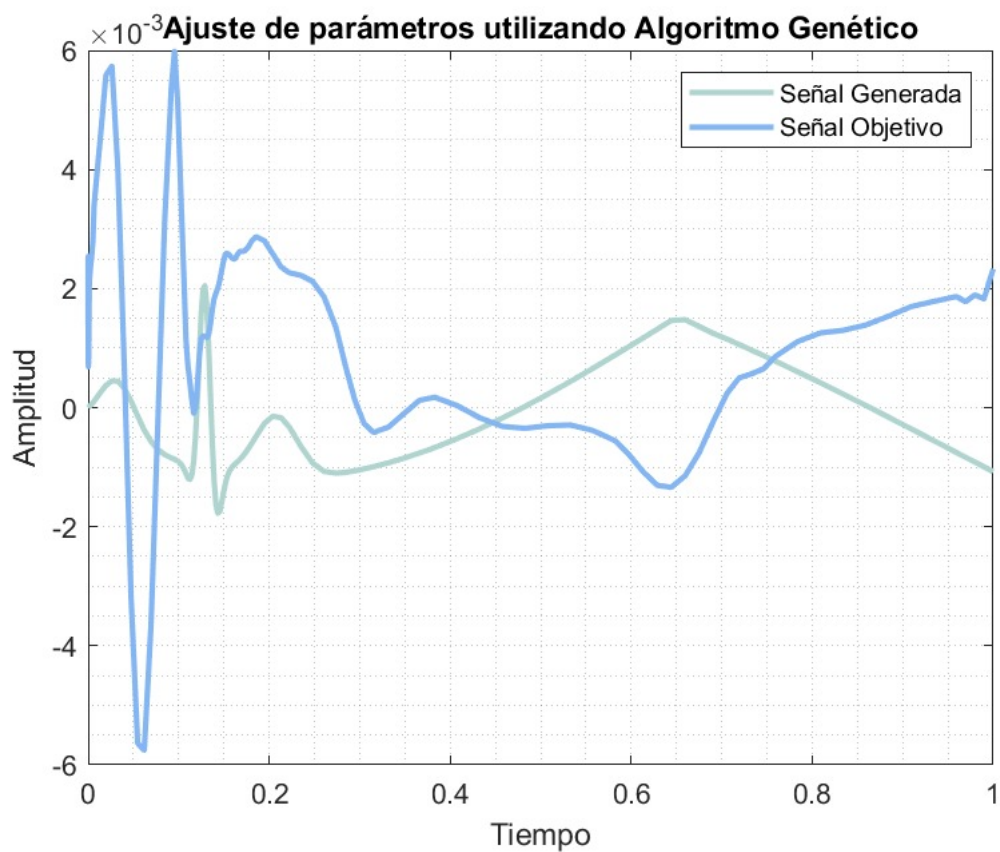


**Figura 3:** Descripción de la primera imagen.

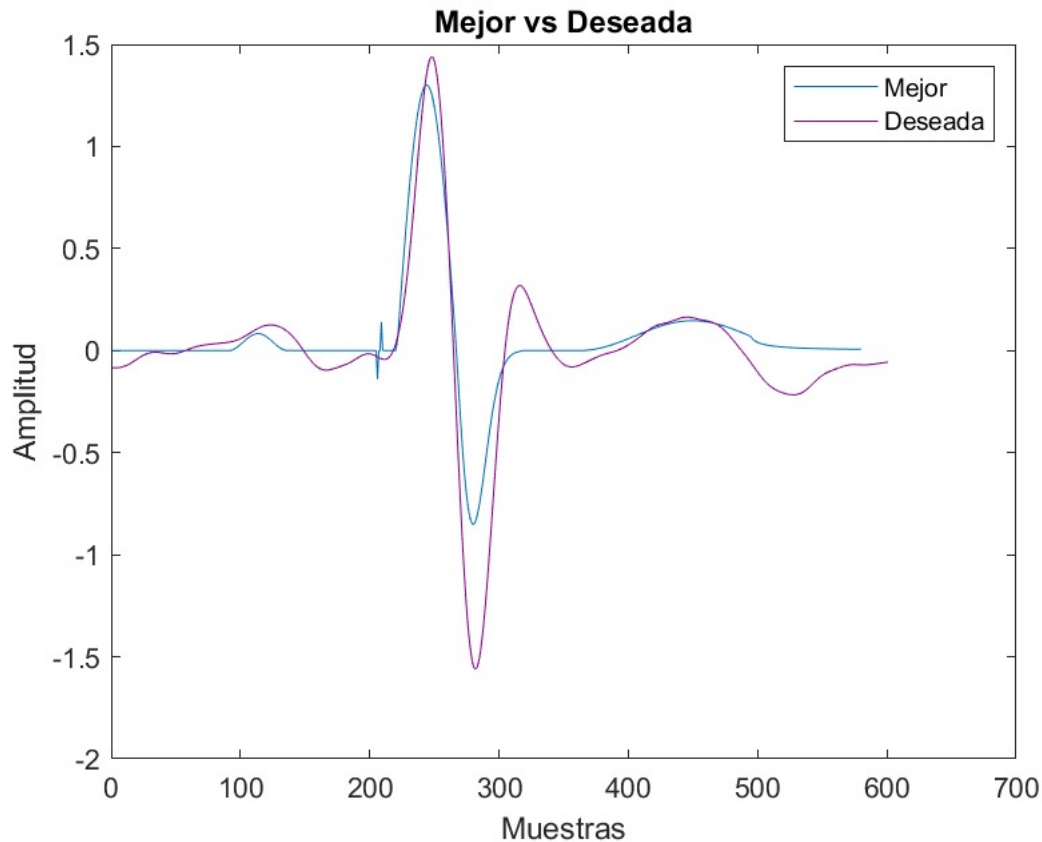


**Figura 4:** Descripción de la segunda imagen.

**Figura 5:** Descripción general de las imágenes.



**Figura 6:** ECG generado por modelo dinámico, comparativa con señal ECG adquirida y ya procesada.



**Figura 7:** ECG generado por modelo de ecuaciones ordinarias

## 4.2. Modelo sintético

# 5. Resultados

## 5.1. Modelo ECG Dinámico

Para el modelo de ECG dinámico, se utilizaron un total de 21 parametros que involucran las 32 muestras de los 4 equipos de cada condición, dando un total de 256 muestras de entrenamiento.

La red neuranal fue disenada con 16 neuronas en su capa de entrada y dos neuronas en su capa de salida. Dentro de las capas ocultas, hay una estructura de 40 neuronas, 80 en la capa intermedia y 40 en la siguiente.

Con un entrenamiento de 1000 epocas se obtuvieron los siguientes resultados:

---

**Algorithm 3** Algoritmo Evolutivo (Mutación) para optimización de parámetros sintéticos - Parte 1

---

```
1: Limpiar, cerrar todo y borrar consola
2: Cargar datos de señales ECG y rangos
3: Inicializar variables y parámetros
4: Establecer etiquetas y rangos para las variables
5: PARÁMETROS INICIALES
6: Probabilidad de Mutación (M): 0.8
7: Número de Generaciones Máximas (gMax): 50
8: Número de Partículas (NP): 16
9: Número Máximo de Partículas Mutantes (maxM): 4
10: Tamaño de la Población (P): 100
11: INICIALIZACIÓN E
12: Para cada señal ECG
13:   Inicializar población y calidad
14:   Iniciar bucle de generaciones
15:     Para cada individuo en la población
16:       Calcular la calidad del individuo
17:       Generar vectores mutantes con probabilidad de mutación
18:       Realizar mutaciones y evaluar calidad
19:       Actualizar la población con individuos trascendentes
20:     Fin bucle de generaciones
21:   Estadísticas y Gráficos
22: Fin Para
```

---

---

**Algorithm 4** Algoritmo Evolutivo (Mutación) - Parte 2

---

```
23: Datos
24: Parametros = {'kB'; 'kP'; 'kPQ'; 'kQ'; 'kR'; 'kS'; 'kST'; 'kT'; 'kI'; 'AP'; 'AQ';
  'AR'; 'AS'; 'AT'; 'Sm'; 'SI'};
25: Valores = bestI(bestT(1,:),:);
26: Valores = Valores';
27: table(Parametros, Valores)
28: Guardar Datos
29: answer = input('Save Data? (1-Yes, 0-No): ');
30: Si answer == 1
31:   params = x(best,:);
32:   filename = input('Enter the name: ','s');
33:   title(filename);
34:   saveas(gcf, [filename, '.png']);
35:   clearvars -except params filename;
36:   save([filename, '.mat']);
37:   disp('Saved');
38: Sino
39:   clear, clc, close all;
40:   disp('Workspace cleared');
41: Fin Si
```

---

Las epocas arrojaron despues del entrenamiento una eficiencia del 100 % como lo muestra la figura 8

```
8/8 [=====] - 0s 1ms/step - loss: 0.0065 - accuracy: 1.0000  
Epoch 9997/10000  
8/8 [=====] - 0s 937us/step - loss: 0.0077 - accuracy: 1.0000  
Epoch 9998/10000  
8/8 [=====] - 0s 933us/step - loss: 0.0060 - accuracy: 1.0000  
Epoch 9999/10000  
8/8 [=====] - 0s 1ms/step - loss: 0.0070 - accuracy: 1.0000  
Epoch 10000/10000  
8/8 [=====] - 0s 2ms/step - loss: 0.0080 - accuracy: 1.0000  
PS C:\Users\rodri\Desktop\Reconocimiento de Patrones\p5>
```

Figura 8: Eficiencia

Obteniendo asi un rendimiento por epoca mostrado en la figura

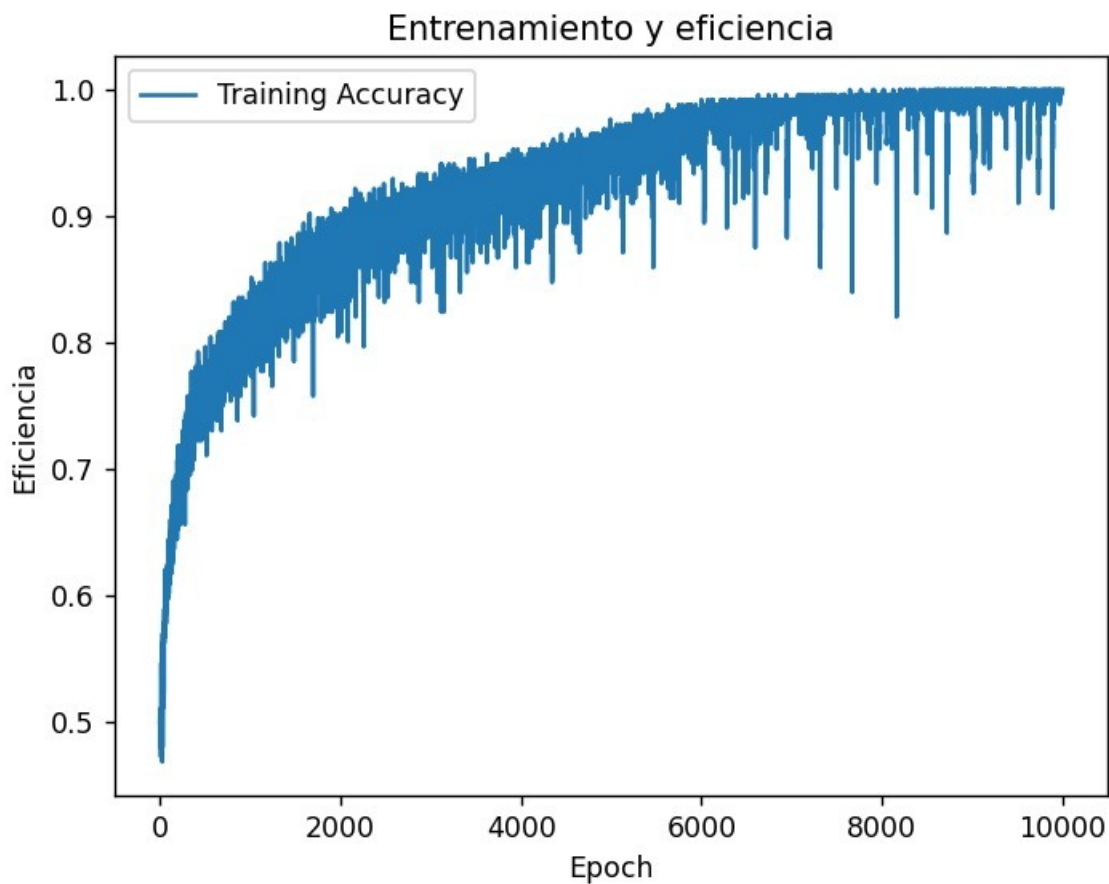


Figura 9: Gráfica de entrenamiento y eficiencia

## 5.2. Modelo ECG Ecuaciones ordinarias

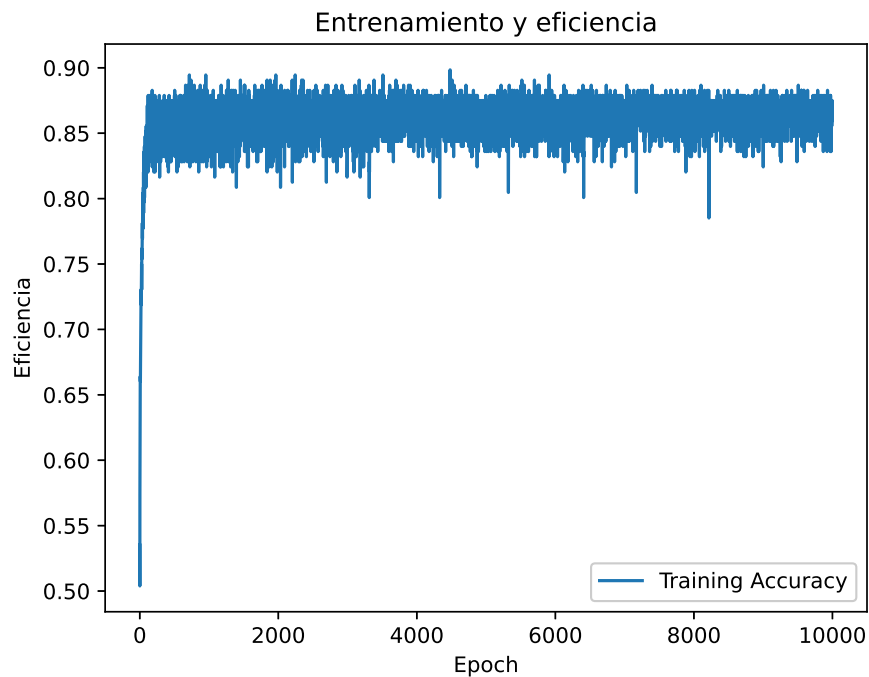
Para el modelo de ECG de ecuaciones ordinarias se utilizaron los 16 parametros arrojados por el modelo para el entrenamiento de la red. La red para la clasificación de estos parametros esta compuesta por una entrada de 16 neuronas, 2 capas ocultas de 20 neuronas y una capa de salida de 2 neuronas. La entrada posee activación RELU, mientras que la salida posee activación softmax y las capas ocultas tienen una activación de tipo sigmoidal.

Se entreno la red con un total de 10 mil epocas y mas de 200 datos que incluyen todos los equipos del grupo, dando como resultado una red entrenada con una eficiencia del 87.11 % como se muestra en la figura 10.

```
Epoch 9994/10000
8/8 [=====] - 0s 2ms/step - loss: 0.1747 - accuracy: 0.8633
Epoch 9995/10000
8/8 [=====] - 0s 2ms/step - loss: 0.1743 - accuracy: 0.8672
Epoch 9996/10000
8/8 [=====] - 0s 1ms/step - loss: 0.1741 - accuracy: 0.8711
Epoch 9997/10000
8/8 [=====] - 0s 4ms/step - loss: 0.1742 - accuracy: 0.8750
Epoch 9998/10000
8/8 [=====] - 0s 2ms/step - loss: 0.1739 - accuracy: 0.8594
Epoch 9999/10000
8/8 [=====] - 0s 2ms/step - loss: 0.1742 - accuracy: 0.8711
Epoch 10000/10000
8/8 [=====] - 0s 920us/step - loss: 0.1741 - accuracy: 0.8711
□
```

**Figura 10:** Resultado de las epocas

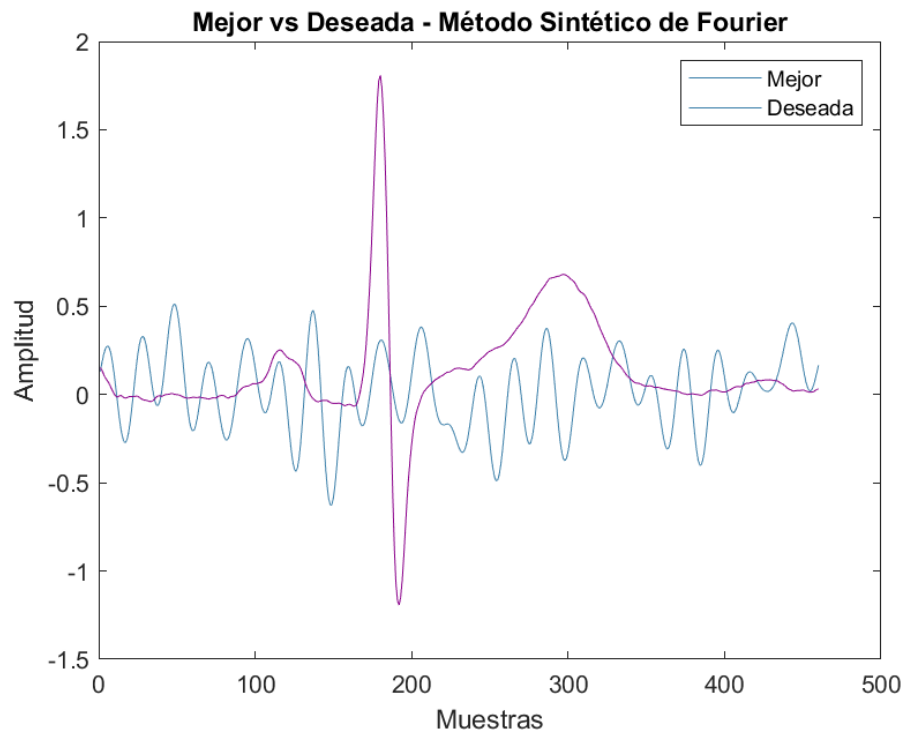
Obtuyendo el rendimiento mostrado en la figura 11



**Figura 11:** Gráfica de entrenamiento y eficiencia

### 5.3. Modelo ECG Fourier

A pesar de ejecutar el algoritmo evolutivo con 200 generaciones y una población de 150, las aproximaciones obtenidas no fueron cercanas a una señal ECG. Es decir, mediante este método no fue posible converger a una solución satisfactoria. En la figura 12 se presentan los mejores resultados mediante este método.



**Figura 12:** Aproximación de señal ECg mediante el método de Fourier.

La figura 12 muestra una señal sintética generada con 30 componentes frecuenciales, lo que a su vez conllevó la optimización de 91 parámetros. Como vemos, la señal obtenida no presenta ningún parecido a la deseada. A pesar de realizarse pruebas con una mayor y menor cantidad de componentes frecuenciales, así como una mayor cantidad de generaciones e individuos, los resultados continuaron siendo insatisfactorios. Por lo tanto, este método se descartó para continuar con la clasificación de señales.

## 6. Conclusiones

### 6.1. Alvarez Perez Karen Yunuen

En el desarrollo de esta practica es importante un correcto tratamiento de los datos para poder obtener resultados precisos, en cuanto a los algoritmos es destacable el uso de funciones que reducen el gasto computacional, en nuestro caso obtuvimos mejores resultados en el modelo dinamico para clasificar el ejercicio y reposo. En conclusión, la generación de señales sintéticas de ECG se presenta como una herramienta valiosa para mejorar el rendimiento y la capacidad de generalización de las redes neuronales en tareas de separación de datos. Sin embargo, se deben abordar cuidadosamente las consideraciones de realismo y validación para garantizar la efectividad de esta estrategia.



## 6.2. Becerra Chávez Alan

La clasificación de Señales de Electrocardiograma por medio de parámetros sintéticos es una herramienta que permite la determinación en el diagnóstico de enfermedades cardíacas, por ende, el seguimiento que se tenga sobre la evolución de dichas enfermedades. Así mismo se puede determinar la detección temprana de anomalías en el ritmo cardíaco, etc. Al finalizar la práctica encontramos que la eficiencia es de 100 %, sin embargo, los estados de excitación en los pacientes (reposo y después de realizar ejercicio intenso) son precursores de que obtengamos una mejor respuesta por medio del modelo dinámico.

## 6.3. Castilla Zamora Jonathan Eduardo

Finalmente, me es posible concluir tras haber realizado esta práctica, en una primera instancia la comprensión de los distintos modelos sintéticos que pueden describir y simular una *señal electrocardiográfica*. En este sentido, cada modelo caracterizado por un conjunto establecido de parámetros requiere un *algoritmo de optimización* a realizar. Profundizando en el aspecto anterior, puedo destacar la implementación de los *Algoritmos Evolutivos*, incluyéndose aspectos como el *elitismo*, la *mutación* y *cruce*; que funcionan como un método para la optimización de dichos parámetros a encontrar que describan la *señal objetivo* (la *señal electrocardiográfica* de los sujetos de prueba).

Por concluir, me es posible evidenciar el procesamiento de una gran cantidad de datos (*parámetros*) a diferenciar con la implementación de *redes neuronales*. En este aspecto, la clasificación de las señales del ECG para pacientes que resultaron de una medición de la actividad eléctrica del corazón en un estado de reposo así como de actividad física moderada. Por tanto, es posible aseverar la importancia de la implementación de los *algoritmos de optimización* en conjunto con la aplicación de *redes neuronales* para el análisis respectivo como reconocimiento de atributos que distinguen, en este caso, señales biológicas.

## 6.4. López Navarrete Gabriel

En el desarrollo de esta práctica, se destaca la importancia de un tratamiento adecuado de los datos para obtener resultados precisos en la clasificación de ejercicios y reposo. Se observa que el uso de algoritmos eficientes que reducen el gasto computacional, como el modelo dinámico empleado, ha conducido a mejores resultados.

La generación de señales sintéticas de ECG emerge como una herramienta valiosa para mejorar el rendimiento y la capacidad de generalización de las redes neuronales en tareas de separación de datos. La inclusión de señales sintéticas proporciona variedad al conjunto de datos, lo que puede contribuir a un modelo más robusto y capaz de manejar diversas situaciones.

Es crucial abordar cuidadosamente las consideraciones de realismo y validación al incorporar señales sintéticas. La validez y relevancia de las señales generadas deben ser evaluadas de manera exhaustiva

para garantizar que el modelo entrenado pueda generalizar de manera efectiva a situaciones del mundo real.

### **6.5. Ortiz Cuapio Manuel Alejandro**

En esta práctica, observamos mejoras notables en comparación con prácticas anteriores. De dichas diferencias tomamos nuestros principales aprendizajes. El primero de ellos es la importancia de procurar estandarizar la adquisición de señales mediante el uso de hardware idéntico, garantizado por un buen diseño y pruebas previas. Además, hubo una mayor eficiencia (práctica y computacional) en el manejo de volúmenes extensos de datos, tanto en su procesamiento como en su análisis. No obstante, debo resaltar que los resultados se pueden ver alterados significativamente debido a deformaciones en las señales adquiridas, lo que señala la importancia crítica de identificar y corregir estas variaciones.

Por otra parte, el desarrollo e implementación de algoritmos evolutivos fue un aspecto esencial en esta práctica, ya que su correcta aplicación fue fundamental para la clasificación precisa de los datos. A lo largo de esta etapa de la práctica se adquirió el siguiente conocimiento: la relevancia de la proporción entre el número de sujetos a mutar y el tamaño de la población, la comprensión de las limitaciones de los métodos sintéticos, la efectividad de la mutación y el elitismo como operadores genéticos exclusivos, así como la relevancia de una distribución de probabilidad uniforme en dichos procesos de mutación. Sin embargo, también se evidenció que el uso de redes neuronales con diseños más refinados resultó innegablemente en la obtención de resultados superiores.

### **6.6. Robellada Rodríguez Alondra Berenice**

La metodología empleada para alcanzar los resultados satisfactorios indicó un riguroso preprocesamiento de los datos, junto con la implementación de algoritmos evolutivos para su optimización. Vale la pena destacar que el uso de modelos sintéticos en la práctica se llevó a cabo bajo condiciones específicas diseñadas para la normalización de todas las adquisiciones. Este enfoque, permitió no solo mejorar la calidad de los resultados, sino también optimizar la eficiencia computacional, lo cual fue evidenciado por los resultados de la red neuronal diseñada, siendo gratificantes con un 100 % en el dinámico y un 87.11 % en el modelo con ecuaciones ordinarias .

### **6.7. Romero Almazan Rodrigo**

El diseño de las redes neuronales está pensado para múltiples entradas, pero tomando siempre en cuenta que la clasificación es de dos tipos, en reposo o después de ejercicio, por lo que nos permitió utilizar herramientas como funciones de pérdida binaria, específicamente BinaryCrossentropy del framework de Keras para Tensorflow.

A pesar de que obtuvimos un 100 % de eficiencia al entrenar la red de los modelos Dinámico, es posible

que se trate de un Overfitting, lo que al momento de corroborar la red con nuevos datos, puede que no tenga la eficiencia deseada. Para corregir esto, normalmente se realizaría un Dropout, o una validación cruzada.

## **6.8. Villeda Ensustegui Kevin Axel**

Durante la practica pudimos obtener diferentes señales de electro cardiogramas sintéticas, con algunos parámetros dados por el profesor, teniendo en cuenta un rango de valores. Dichas señales sintéticas tuvimos que implementar un método de optimización para poder generar nuestras señales lo mas parecidas a nuestra señal base. Dicho método nos sirve para poder hacer un procesamiento de señales bastante adecuado. Cabe destacar la eficiencia de las señales obtenidas después de la optimización, así como también tenemos que destacar el correcto diseño de las señales artificiales, a partir de modelos matemáticos dados.

## **Referencias**

[1] Lung National Heart and Blood Institute. Electrocardiogram, 2020.